

Convex Optimization

shijuanfeng

2014-01-23

Chapter 1 引言

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && f_i(x) \leq b_i, \quad i = 1, \dots, m \\ & && x \in \mathcal{R}^n \end{aligned}$$

- 理论: Ch2-5 凸集, 凸函数, 凸优化问题, 对偶
- 应用: Ch6-8 拟合, 统计估计, 几何问题
- 算法: Ch9-11 无约束优化, 等式优化, 内点法
- 附录: 数学知识
- 软件包: LOQO、MOSEK、AMPL、GAMS

Chapter 2 凸集

- 仿射集+凸集→锥
- 重要例子：超平面&半空间；多面体；3类球；2类锥
- 保凸运算：交，仿射函数，线性分式&透视函数
- 分离和支撑超平面：定义+定理
- 广义不等式：定义、性质、最小与极小元
- 对偶锥与广义不等式：对偶锥、广义不等式的对偶、最小元、极小元的对偶性

Chapter 3 凸函数

➤ 凸函数： 定义（一阶、二阶）、例子（下水平集、上境图）、
Jensen不等式

➤ 保凸运算： 5个

➤ 共轭函数： 定义、例子、5条性质

➤ 拟凸函数： 定义、例子、3个性质、保拟凸运算
函数的定义域和任意下水平集为凸集

➤ 对数凹函数&对数凸函数： 定义、例子、定理、性质

➤ 广义不等式的凸性： 单调性定义、凸性定义、定理

Chapter 4 凸优化问题

- 优化问题： 定义、术语、局部最优、等价形式
 - 凸优化问题： 定义、局部最优、微分条件、等价形式
 - 拟凸优化问题： 定义、二分法求解
-
- 线性规划（LP）： 定义、几种形式、举例
 - 二次优化（QP）： 定义、特例、举例
 - 二阶锥规划（SOCP）： 定义、举例
 - 几何规划（GP）： 定义、转化、举例
-
- 广义不等式下的凸问题： 定义、特例、举例
 - 向量优化： 定义

Chapter 5 对偶

- Lagrange对偶函数：定义、例子、和共轭函数
- Lagrange对偶问题：强对偶，弱对偶
- 最优性条件：互补松弛，KKT
- 扰动与灵敏度分析
- 择一定理：弱择一，强择一
- 广义不等式

对偶函数始终是求极小值、凹函数

原问题:

$$\begin{aligned} & \text{minimize} && f_0(x), \quad x \in \mathcal{R}^n \\ & \text{subject to} && f_i(x) \leq 0, \quad i = 1, \dots, m \\ & && h_i(x) = 0, \quad j = 1, \dots, p \end{aligned}$$

Lagrange 函数:

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x)$$

Lagrange 对偶函数:

$$g(\lambda, \nu) = \inf_{x \in D} L(x, \lambda, \nu) = \inf_{x \in D} (f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x))$$

凸优化问题的对偶求解

设原始优化问题与对偶问题具有强对偶性，且 (λ^*, ν^*) 为对偶问题的最优解。 $L(x, \lambda^*, \nu^*)$ 存在唯一的最小解，即

$$\text{minimize } f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p \nu_i^* h_i(x)$$

存在唯一解 x^* 。

若 x^* 为原始问题的可行解，则 x^* 即为原始问题的最优解；
若 x^* 不是原始问题的可行解，则原始问题不存在最优解。

原始优化问题与对偶问题不具有强对偶性，
那么对偶问题最优解给出了原问题最优值的下界。 **P208**

KKT优化条件

P235

minimize $f_0(x)$, $x \in \mathcal{R}^n$ <http://shijuanfeng.blogbus.com/>

subject to $f_i(x) \leq 0, i = 1, \dots, m$

$h_j(x) = 0, j = 1, \dots, p$

$$g(\lambda, \nu) = \inf_{x \in D} (f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{j=1}^p \nu_j h_j(x))$$

设优化问题中，函数 $f_0(x), \dots, f_m(x), h_0(x), \dots, h_p(x)$ 可微。设 x^* 为原始优化问题的最优解， (λ^*, ν^*) 为对偶问题的最优解，且两者具有强对偶性，则 (x^*, λ^*, ν^*) 满足如下条件：

1. $f_i(x^*) \leq 0, i = 1, \dots, m$

原问题的解要满足

2. $h_i(x^*) = 0, i = 1, \dots, p$

3. $\lambda_i^* \geq 0, i = 1, \dots, m$

互补松弛性 p234

4. $\lambda_i^* f_i(x^*) = 0, i = 1, \dots, m$


KKT条件为
必要条件！

5. $\nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{j=1}^p \nu_j^* \nabla h_j(x^*) = 0$

对偶问题的解要满足

Chapter 9 无约束优化

$$\text{minimize } f(x)$$

- 梯度下降 
 - batch gradient descent
 - stochastic/incremental gradient descent

Matlab Demo——Andrew Ng coursera 学习课程\week2

- 牛顿法

- 比较

<http://www.blogbus.com/shijuanfeng-logs/231557216.html>

Chapter 10 等式约束优化


minimize $f(x)$

subject to $Ax = b$

- 解析方法（代入法）
- Newton方法（可行&不可行初始点）

Chapter 11 不等式约束极小化问题

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && f_i(x) \leq 0, i = 1, \dots, m \\ & && Ax = b \end{aligned}$$



$$\begin{aligned} & \text{minimize} && f_0(x) + \sum_{i=1}^m I_-(f_i(x)) \\ & \text{subject to} && Ax = b \end{aligned} \quad I_-(u) = \begin{cases} 0 & u \leq 0 \\ \infty & u > 0 \end{cases}$$

1. 解决不可微：对数近似，精度： m / t
2. 可微后的解决办法：
求解等式约束的方法（梯度下降、**Newton法**）

其他

➤ 下一本书 投票

1. 模式分类
2. Pattern Recognition and Machine Learning
3. The Elements of Statistical Learning

➤ One idea: 共同维护一份最新资讯

<http://shijuanfeng.blogbus.com/>

Thanks!